

Propuesta de Trabajo Final Integrador

Alumno: WLODECK, FABRICIO JOAQUÍN

Contexto y Objetivo

La mandioca (*Manihot esculenta*) es un arbusto perenne de la familia de las euforbiáceas extensamente cultivado en regiones tropicales y subtropicales de América, África y Oceanía por sus raíces ricas en almidones de alto valor alimentario. En Argentina, este cultivo representa una actividad económica fundamental para la región del nordeste (NEA), particularmente en la provincia de Misiones, que concentra el 84,7% de las casi 30 mil hectáreas cultivadas en el país.

Sin embargo, la producción de mandioca enfrenta desafíos significativos relacionados con la presencia de diversos patógenos que afectan severamente el rendimiento y la calidad de las raíces comerciales. Estos patógenos pueden ocasionar pérdidas de hasta el 60% en el rendimiento del cultivo, representando una amenaza económica considerable para los productores de la región. Entre las enfermedades más relevantes se encuentran el mosaico común de la mandioca (causado por el *Cassava Common Mosaic Virus* - CsCMV), la bacteriosis de la mandioca (*Cassava Bacterial Blight* - CBB), la enfermedad de rayas marrones (*Cassava Brown Streak Disease* - CBSB), y el moteado verde (*Cassava Green Mottle* - CGM).

La detección temprana de estas enfermedades es crucial para implementar medidas de control efectivas, que en muchos casos incluyen la eliminación de plantas infectadas mediante quema para evitar la propagación del patógeno a otras áreas del cultivo. No obstante, la identificación visual de síntomas por parte de los productores puede ser compleja, requiriendo experiencia y conocimiento especializado, y frecuentemente ocurre cuando la enfermedad ya se ha extendido considerablemente.

En este contexto, el desarrollo de sistemas automatizados de clasificación de enfermedades basados en imágenes representa una herramienta de gran valor para asistir a los productores en la toma de decisiones oportunas. El objetivo principal de este trabajo es desarrollar un sistema de clasificación que pueda identificar la presencia y tipo de patógeno que afecta a las plantas de mandioca utilizando fotografías capturadas con dispositivos de bajo costo (cámaras de teléfonos celulares, cámaras compactas no profesionales), haciendo énfasis en la accesibilidad y viabilidad de implementación en contextos productivos reales.

El sistema deberá ser capaz de distinguir entre plantas saludables y aquellas afectadas por cuatro tipos de patógenos diferentes, proporcionando información confiable y explicable que permita a los productores tomar decisiones fundamentadas sobre el manejo de sus cultivos.



Figura 1. Mandioca (*Manihot esculenta*)

Datos Disponibles

El conjunto de datos proporcionado para este trabajo consiste en imágenes de plantas de mandioca capturadas en diferentes lotes de cultivo bajo condiciones reales de producción. Las características principales del *dataset* son:

- Imágenes de diferentes partes de la planta (hojas, tallos, y en algunos casos raíces), determinar si sirve toda la información o no.
- Fotografías capturadas con dispositivos no profesionales.
- Variabilidad en condiciones de captura (iluminación, ángulos, distancias, fondos).
- Diferentes estados de desarrollo de la enfermedad (síntomas tempranos y avanzados).

Las imágenes se encuentran clasificadas según cinco categorías, codificadas en un archivo CSV con la siguiente estructura:

Etiqueta	Descripción
0	Cassava Bacterial Blight (CBB)
1	Cassava Brown Streak Disease (CBSD)
2	Cassava Green Mottle (CGM)
3	Cassava Mosaic Disease (CMD)
4	Saludable

- [Link a los datos](#)

Consideraciones importantes del dominio:

- Algunas enfermedades presentan síntomas visuales similares en etapas tempranas
- La calidad de las imágenes puede variar significativamente debido al uso de dispositivos no profesionales
- Las condiciones de iluminación natural en campo pueden introducir variabilidad en el aspecto de los síntomas
- La confusión entre ciertas clases puede tener implicaciones económicas diferentes (ej: identificar erróneamente una planta saludable como enferma vs. no detectar una planta enferma)

Objetivos Específicos

El desarrollo del trabajo final deberá cumplir con los siguientes objetivos específicos:

1. **Desarrollar un pipeline completo de clasificación** que integre extracción de características mediante *transfer learning* y modelos de clasificación, optimizado para operar con imágenes capturadas en condiciones no controladas.
2. **Evaluar y seleccionar arquitecturas de redes neuronales pre-entrenadas como extractores de características (backbones)**, considerando el balance entre capacidad representacional, costo computacional, y requerimientos de recursos para su implementación en contextos con limitaciones tecnológicas.
3. **Diseñar e implementar estrategias de transfer learning** apropiadas para el dominio agrícola, explorando técnicas de *fine-tuning*, *feature extraction*, y entrenamiento de capas de clasificación personalizadas.
4. **Explorar modelos de clasificación sobre embeddings**, incluyendo tanto arquitecturas *end-to-end* (redes neuronales completas) como clasificadores clásicos de *machine learning* (Random Forest, SVM, XGBoost, etc.) operando sobre características extraídas por el *backbone*.

5. **Definir y calcular métricas de evaluación apropiadas** para el contexto del problema, considerando la importancia diferencial de los errores de clasificación y el impacto de las confusiones entre clases específicas en la toma de decisiones productivas.
6. **Implementar técnicas de explicabilidad** para interpretar las decisiones del modelo, verificar que no opera bajo sesgos espurios, y generar confianza en los usuarios finales del sistema. Existen varios métodos para esto, pero se recomienda utilizar [LIME](#) (ya implementado y funcional).
7. **Optimizar hiperparámetros del *pipeline*** mediante técnicas sistemáticas (Grid Search, Random Search, optimización bayesiana, algoritmos genéticos), documentando el proceso y justificando las configuraciones finales seleccionadas.
8. **Analizar la importancia de características** para fundamentar la selección del *backbone* y comprender qué aspectos visuales son más relevantes para la discriminación entre clases.
9. **Evaluar la robustez del modelo** frente a variaciones en las condiciones de captura y analizar su comportamiento ante casos límite o ambiguos.