

Resumen — Consigna y avance del Trabajo Final Integrador

Asignatura: IC522 · Inteligencia Computacional

Alumno: WLODECK, Fabricio Joaquín

Tema: Clasificación de enfermedades en mandioca a partir de imágenes (5 clases)

Última actualización: 28/09/2026

1. Consigna (8 ítems de la cátedra)

#	Ítem	Estado	Nota
1	Pipeline completo de clasificación con transfer learning (backbones sin cabeza + cabeza propia)	En progreso	Comparación MobileNetV2/V3 y EfficientNetB0 hecha en el intento previo
2	Evaluar backbones: capacidad vs costo computacional (contexto móvil, baja capacidad)	En progreso	Candidato: MobileNetV2 (menor # parámetros / inferencia)
3	Estrategias de transfer learning: fine-tuning, feature extraction, cabeza propia	En progreso	Fine-tuning a medias: hay que robustecerlo
4	Clasificadores sobre embeddings (Random Forest, SVM, XGBoost)	Pendiente	Aún queda por implementar
5	Métricas con costo diferencial de errores entre clases	Definido	Falsos negativos = los más importantes (saludable ↔ enferma)
6	Explicabilidad (LIME) + verificación de sesgos espurios	Pendiente	LIME ya funcional en el intento previo; falta integrarlo al pipeline
7	Optimización de hiperparámetros (Grid/Random Search, bayesiana, genéticos)	Pendiente	Falta definir método y documentar configuraciones
8	Robustez ante variaciones de captura y casos límite	Pendiente	"Las peores fotos posibles": ruido, baja luz, desenfoque

2. Dataset (verificado en el EDA)

Aspecto	Resultado
---------	-----------

Registros	26,337 × 3 (image_id , label , source); sin nulos ni IDs duplicados
Imágenes	26,337 .jpg (3.09 GiB), 1:1 con el CSV; 0 duplicados exactos (SHA-1 completo); 0 corruptas
Clases	CBB 5.67 % · CBSD 13.20 % · CGM 11.46 % · CMD 58.71 % · Saludable 10.97 % → desbalance 10.36 : 1
Fuentes	2020: 81.24 % · 2019: 18.76 %; las 4,940 de 2019 se llaman train-<clase>-N.jpg (el nombre revela la etiqueta → no usar como feature)
Dimensiones	Dominante 800×600 (80.4 %), mediana 119.5 KB; solo 3.4 % casi cuadradas
Captura	Brillo/contraste casi idénticos entre clases → sin sesgo de captura por clase
Preprocesamiento propuesto	Split estratificado 70/15/15 (semilla 42, verificado por clase y por source); Resize(256)+CenterCrop(224) ; normalización ImageNet

3. Desarrollado hasta ahora

3.1 Intento previo — ref_personal\pruebas_marzo_Manihot_diseases_detection.ipynb (179 celdas)

- Preprocesamiento, exploración y subset del 30 % para pruebas rápidas.
- Comparación de backbones ligeros: **MobileNetV2, MobileNetV3, EfficientNetB0**.
- Detección y eliminación de anomalías por clusterización.
- Tres estrategias de balanceo: recorte (undersampling), pesos de clase y sin balancear.
- Modelos 1–7: MobileNetV2 a 224×224, EfficientNetB0/B4/B7 (hasta 512×512), versión "con datos del paper".
- Mejor resultado anotado: **F1 macro avg ≈ 75 %** sobre test balanceado (80/20).
- **LIME implementado y funcional**; referencia a tf-explain / Grad-CAM.
- Pendiente: completar el fine-tuning.

3.2 EDA actual — 01_EDA_mandioca.ipynb (38 celdas, ejecutado, 0 errores, 7 figuras)

- Fases completas: diccionario → integridad/calidad → distribución y desbalance → fuentes/sesgo de dominio → análisis de imágenes (dimensiones, aspecto, brillo, montajes por clase, no informativas) → split y preprocesamiento → conclusiones.
- Entregables HTML y PDF en reportes\ (incluye el gráfico de torta de distribución por clase).

3.3 Instrucciones de trabajo

- INSTRUCCION_EDA_mandioca.md : labor detallada (Fases 0–8) con los valores de control verificados.
- 01_EDA_mandioca.py : exportación en porcentajes del notebook para revisar código suelto.

3.4 Organización de carpetas

- `consigna¬as\` — consigna y notas propias.
- `datos\` — CSV, imágenes y zip.
- `ref_personal\` — intentos previos.
- `reportes\` — HTML/PDF y resúmenes: de ahora en más, todo documento de explicación/resumen va aquí.
- Raíz — código (`.ipynb` , `.py`) e instrucciones.

4. Próximos pasos (por ítem de la consigna)

1. **Ítem 4** — Entrenar backbones sin cabeza, extraer embeddings y comparar RandomForest / SVM / XGBoost sobre ellos.
2. **Ítem 3** — Fine-tuning robusto del mejor backbone (descongelamiento progresivo, augmentation acotada).
3. **Ítem 6** — LIME sobre el modelo final + verificación de sesgos (fondo, iluminación, source).
4. **Ítem 7** — Búsqueda de hiperparámetros (Random Search o bayesiana) documentando cada configuración.
5. **Ítem 8** — Test de robustez con "las peores fotos": ruido, baja luz, desenfoque, hoja parcial fuera de cuadro.
6. **Ítem 5** — Reportar métricas finales con matriz de confusión normalizada y costo asimétrico de errores.